

Trabajo Práctico Número 1

GitHub: <https://github.com/AguFigueroa/Grupo-4---Taller-de-programaci-n/tree/main/TP1>

1. Introducción y Marco Teórico: La Medición de la Informalidad Laboral

La Encuesta Permanente de Hogares (EPH), relevada de forma sistemática por el INDEC, es la herramienta clave para diagnosticar la situación socioeconómica y el mercado de trabajo en Argentina. Dentro de este análisis, la informalidad laboral es uno de los indicadores más críticos para evaluar el bienestar de la población.

Para identificar a los trabajadores informales, el INDEC sigue criterios vinculados a la falta de registro y de derechos laborales básicos. En términos prácticos, el universo informal está compuesto por los asalariados "en negro" (sin descuentos jubilatorios) tanto en empresas formales como informales, los cuentapropistas o patrones que no están registrados ante la AFIP, el servicio doméstico no registrado en el sector de hogares y los trabajadores familiares sin remuneración, dado que están excluidos de los marcos legales tradicionales.

2. Metodología de Datos, Proceso de Limpieza y Filtros


Este estudio empleó microdatos de la EPH del cuarto trimestre de 2024 y 2025. El proceso comenzó armonizando variables y validando la consistencia de datos entre períodos para permitir su fusión (ver Tablas 1 y 2 en el Anexo).

La limpieza de datos eliminó inconsistencias lógicas y respuestas ambiguas. Se imputaron valores faltantes (NaN) a registros con códigos de no-respuesta en variables como Edad (CH06), Nivel Educativo (NIVEL_ED), Categoría Ocupacional (CAT_OCUP), y otras vinculadas al empleo y salud. También se excluyeron observaciones con ingresos negativos en la ocupación principal (P21) e ingreso total individual (P47T) por carecer de sentido económico.

Como paso previo al análisis, evaluamos la tasa de respuesta sobre la condición de actividad (ESTADO). Se detectó que un total de 121 individuos no respondieron a esta pregunta (ESTADO = 0), por lo que fueron separados en la base "norespondieron" y excluidos del estudio principal.

Con la muestra que sí contestó (ESTADO $\neq$ 0), aislamos únicamente a la población ocupada (ESTADO = 1), conformando la subbase ocupados. Esto es metodológicamente necesario ya que el análisis de la informalidad aplica exclusivamente sobre las personas que están trabajando. Para controlar cómo impactan estos filtros en la calidad de los datos, la Figura 1 presenta un mapa de calor (heatmap) comparativo. Allí se observa que las variables sociodemográficas básicas tienen prácticamente un 0% de faltantes, mientras que las variables de empleo e ingresos estabilizan sus patrones de respuesta una vez que nos enfocamos en el universo de ocupados.

Figura 1: Porcentaje de valores faltantes por variable, año y base



Fuente: elaboración propia en base a INDEC

3. Análisis Exploratorio y Estructura de Relaciones Lineales

Para caracterizar la muestra unificada de la EPH, se presentan en la Tabla 1 los estadísticos descriptivos del perfil sociodemográfico e ingresos de la población activa (ver detalles en la Tabla 4 del Anexo).

Los datos reflejan estabilidad sociodemográfica: la proporción de mujeres se mantiene entre 52-53%, la edad promedio en 37 años y el nivel universitario en 14%. El cambio más notable es la caída en la cobertura de salud (obra social o prepaga), que pasó del 70% en 2024 al 68% en 2025.

Los ingresos (ajustados por un factor IPC de 1,3141) muestran leves alzas en los promedios: la ocupación principal subió de \$352.742 a \$364.445 y el ingreso total individual de \$528.852 a \$544.200. No obstante, la mediana de \$0 revela una alta inactividad o desocupación. Asimismo, la amplia dispersión y máximos de \$30 millones evidencian una fuerte desigualdad y la influencia de valores atípicos que elevan los promedios. Para evaluar cómo se relacionan las variables entre sí y detectar si hubo cambios estructurales entre ambos años, se calcularon las matrices de correlación lineal de Pearson para el cuarto trimestre de 2024 y de 2025 (ver Figura 2).

Tabla 1: Estadísticas descriptivas de variables sociodemográficas, de educación y salud


Variable	Año	N	Media	Desv. Est.	Min	P25	P50	P75	P99	Max
Edad	2024	46.804	36,76	22,19	0	18	35	54	85	103
	2025	43.638	37,59	22,33	1	19	36	55	86	101
Mujer	2024	46.804	0,52	0,50	0	0	1	1	1	1
	2025	43.638	0,53	0,50	0	0	1	1	1	1
Jefe/a de hogar	2024	46.804	0,35	0,48	0	0	0	1	1	1
	2025	43.638	0,36	0,48	0	0	0	1	1	1
Cónyuge o pareja	2024	46.804	0,17	0,38	0	0	0	0	1	1
	2025	43.638	0,17	0,38	0	0	0	0	1	1

Hijo/a del hogar	2024	46.804	0,37	0,48	0	0	0	1	1	1
	2025	43.638	0,36	0,48	0	0	0	1	1	1
Unido/a o casado/a	2024	46.804	0,38	0,48	0	0	0	1	1	1
	2025	43.637	0,38	0,48	0	0	0	1	1	1
Tiene cobertura médica	2024	46.762	0,70	0,46	0	0	1	1	1	1
	2025	43.535	0,68	0,46	0	0	1	1	1	1
Secundario completo o más	2024	46.804	0,49	0,50	0	0	0	1	1	1
	2025	43.638	0,49	0,50	0	0	0	1	1	1
Univ. completo o más	2024	46.804	0,14	0,35	0	0	0	0	1	1
	2025	43.638	0,14	0,35	0	0	0	0	1	1

Fuente: elaboración propia en base a INDEC

Metodológicamente, las variables categóricas pierden precisión analítica al carecer de una escala de magnitud real. Por ello, utilizamos las variables categóricas binarias creadas para hacer la matriz (figura 2). Cabe aclarar que, al provenir varias de estas dummies de una misma variable categórica, es esperable que presenten una fuerte correlación entre sí (perfecta en algunos casos) por construcción (por ejemplo, sector formal e informal, o cuenta propia y asalariado/a), por lo que dichos coeficientes carecen de valor analítico. Sin embargo, esta desagregación resulta útil para analizar la asociación de cada categoría específica con el resto de las variables del cuadro, algo que la matriz anterior no permitía captar. En términos generales, los patrones de correlación se mantienen prácticamente idénticos entre 2024T4 y 2025T4, con variaciones mínimas en los coeficientes, lo que sugiere una alta estabilidad en la estructura de relaciones entre estas variables de un año a otro. Se observan vínculos sólidos y estables entre el Ingreso de la Ocupación Principal (P21) y el Ingreso Total Individual (P47T), con correlaciones positivas de ~0,86 y ~0,88. Asimismo, la Edad (CH06) muestra una asociación positiva moderada con los ingresos, validando que la experiencia laboral acumulada mejora las remuneraciones.

Figura 2: Matriz de correlaciones entre variables usando categóricas binarias



Fuente: elaboración propia en base a INDEC.

Definición y Medición de la Informalidad Laboral

Basado en Maurizio & Monsalvo (2021), este análisis define el indicador de Trabajadores Independientes Formales (*Formal self-employed*) mediante el cruce de categoría ocupacional, tamaño del establecimiento y nivel educativo.

Operativamente, el segmento incluye:

- Patrones Formales: empleadores ($CAT_OCUP=1$) en establecimientos con más de 5 empleados ($PP04C>5$).
- Cuentapropistas Profesionales: independientes sin empleados ($CAT_OCUP=2$) con título universitario completo ($NIVEL_ED=6$).

Los casos restantes de patrones y cuentapropistas se agruparon como "Sector Informal". La Tabla 2 detalla la evolución de este indicador entre 2024 y 2025.

Tabla 2: Proporción de Trabajadores Independientes Formales e Informales por año y sexo

Año	Grupo	Formal Self-employed	Informal
2024	Total	21,78	78,22
	Mujeres	27,11	72,89
	Hombres	18,32	81,68
2025	Total	20,94	79,06
	Mujeres	25,81	74,19
	Hombres	17,59	82,41

Fuente: elaboración propia en base a INDEC


7. Análisis Gráfico de la Distribución de Ingresos

Para evaluar brechas de bienestar, la Figura 3 expone la distribución de ingresos de la ocupación principal y totales. Los trabajadores informales muestran una distribución de ingresos muy concentrada en valores bajos, con un pico marcado cerca del origen y caída abrupta luego del primer millón de pesos. Los formales, en cambio, presentan una distribución más achatada y con cola más larga, reflejando mayor dispersión e ingresos más altos, patrón que se repite en 2024 y 2025.

/El análisis reconoce limitaciones en las variables de la EPH:

- P21: Aísla el retorno del trabajo principal, pero ignora ingresos secundarios o rentas, subestimando recursos en independientes.
- P47T: Refleja el poder de compra total, pero dificulta atribuir el bienestar exclusivamente a la categoría laboral debido a la mezcla de fuentes de ingresos.
- Ambas tienen un porcentaje considerable de valores faltantes que puede sesgar la distribución, están sujetas a subdeclaración (especialmente entre informales),

Figura 3: Kernel e histograma de “Formal Self-employed”
Distribución de ingresos: formal self-employed vs resto, 2024 y 2025 (Densidad)



Fuente: elaboración propia en base a INDEC

8. Uso de Herramientas de IA y Reflexión Final

En cumplimiento con las pautas de transparencia de la cátedra, se explicita el uso de modelos de lenguaje (LLM) como ChatGPT, Claude y Gemini a lo largo del desarrollo de este trabajo práctico. El uso de la IA resultó una herramienta sumamente efectiva para optimizar los tiempos de programación, sirviendo principalmente para la automatización de la limpieza de datos con Pandas, la resolución de errores sintácticos de código y el diseño estético de las figuras y heatmaps de Seaborn y Matplotlib.

No obstante, se identificaron limitaciones claras en la interpretación de las consignas metodológicas y en la construcción del indicador específico de informalidad, donde las sugerencias iniciales de los modelos debieron ser descartadas y corregidas manualmente por el grupo para adecuarse estrictamente al paper de Maurizio & Monsalvo (2021). Para la realización completa de este trabajo práctico, el grupo dedicó un tiempo total estimado de 24 horas.

Ápndice: uso de herramientas de IA

Chat GPT

“me da error este código:

```
import pandas as pd
```

```
import os
```

```
from google.colab import drive drive.mount('/content/drive') ## aca me da error
```

```
ruta = "/content/drive/MyDrive/Taller de Programacion '26"
```

```
base_2024 = pd.read_excel(os.path.join(ruta, "usu_individual_T424.xlsx")) base_2025 =  
pd.read_excel(os.path.join(ruta, "usu_individual_T425.xlsx"))”
```

“estoy teniendo este problema al correr el código(imagen adjunta): esto es lo que tengo hasta ahora.” (código pegado)

“cuando hago un print de tipo_datos_final veo que es igual a tipo_datos te paso el diccionario de las variables, esto esta bien?”

“con el punto 2.a cerrado quiero revisar el punto 2.b, quiero que me generes una base para el código, teniendo en cuenta el diccionario de las variable”

“Tendría que repetir la limpieza para cada base? se llaman base_2024_tp1 y base_2025_tp1. Te paso la consigna para que me des una recomendación de si hacerlo uniendo ambas bases o trabajando por separado”

“Ayúdame a generar el código para el punto 5 (creación de variables binarias) de la pauta adjunta, adjunto el .py de lo que tengo hasta este momento”

“Este código corrió bien, pero no veo guardado el excel, que puede estar pasando? tipo_datos.to_excel('tablas\tipo_datos.xlsx', index=False)”

“como hago para generar una figura de heatmap el porcentaje de valores faltantes de las variables seleccionadas para cada año (NaN en Python) en la base respondieron versus la base ocupados. las variables seleccionadas que tengo son: (código pegado)”

“En el punto 8 de la letra, entiendes que se refiere a hacer dos heatmaps (uno para cada año y comparar) o se refiere a en un solo gráfico donde se muestran los años por separado?”

“con este código me queda en blanco la figura, ¿qué puede estar pasando? (codigo pegado)”

“tengo el código que pego abajo para generar la tabla descriptiva, como puedo hacer para que me queden las variables en las filas, separadas por año?(codigo pegado)”

“dame una recomendación de cómo generaría un indicador de estado laboral, lo voy a llamar "formal self employed", debería tener a los dueños de empresas con más de 5 empleados y a los profesionales independientes”

“me salen los warnings de la imagen adjunta, debería preocuparme?”

“Quiero hacer una tabla de doble entrada, mujeres, hombres y total en las filas, columnas formal e informal, esto sobre la base filtrada `base_fse = ocupados.dropna(subset=['formal_self_employed']).copy()` . Quiero usar las variables binarias que ya tengo definidas. Lo que debe ir en las celdas es el porcentaje de trabajadores, dame una base para este código.”

“a este gráfico le quiero corregir algunas cosas: no se ve la leyenda (debería ser una sola), la leyenda del eje x y la nota se sobreponen. Dame el código corrigiendo estos detalles”

Anexo

Tabla 1: Revisión del tipo de datos

Variable	Tipo 2024	Tipo 2025	¿Son el mismo tipo?
CH04	int64	int64	TRUE
CH06	int64	int64	TRUE
CH07	int64	int64	TRUE
CH08	int64	int64	TRUE
NIVEL_ED	int64	int64	TRUE
ESTADO	int64	int64	TRUE
CAT_OCUP	int64	int64	TRUE
EMPLEO	float64	float64	TRUE
SECTOR	float64	float64	TRUE
PP04C	float64	float64	TRUE
PP04D_COD	float64	float64	TRUE
P21	int64	int64	TRUE
P47T	float64	float64	TRUE
REGION	int64	int64	TRUE
CH03	int64	int64	TRUE
CODUSU	object	object	TRUE
ANO4	int64	int64	TRUE
TRIMESTRE	int64	int64	TRUE
NRO_HOGAR	int64	int64	TRUE
PONDERA	int64	int64	TRUE

Fuente: elaboración propia en base a INDEC

Tabla 2: Revisión del tipo de datos - Post-armonización

Variable	Tipo 2024	Tipo 2025	¿Son el mismo tipo?
CH04	int64	int64	TRUE
CH06	int64	int64	TRUE
CH07	int64	int64	TRUE
CH08	int64	int64	TRUE
NIVEL_ED	int64	int64	TRUE
ESTADO	int64	int64	TRUE
CAT_OCUP	int64	int64	TRUE
EMPLEO	float64	float64	TRUE
SECTOR	float64	float64	TRUE
PP04C	float64	float64	TRUE
PP04D_COD	float64	float64	TRUE
P21	int64	int64	TRUE
P47T	float64	float64	TRUE
REGION	int64	int64	TRUE
CH03	int64	int64	TRUE
CODUSU	object	object	TRUE
ANO4	int64	int64	TRUE
TRIMESTRE	int64	int64	TRUE
NRO_HOGAR	int64	int64	TRUE
PONDERA	int64	int64	TRUE

Fuente: elaboración propia en base a INDEC

Tabla 3: Comparación NaN antes y después de unificar datos

Variable	NaN antes de <i>merge</i>	NaN después de <i>merge</i>	Nuevos NaN por limpieza
CH04	0	0	0
CH06	0	553	553
CH07	0	0	0
CH08	0	156	156
NIVEL_ED	0	0	0
ESTADO	0	0	0
CAT_OCUP	0	6	6
EMPLEO	49.733	49.759	26
SECTOR	49.733	51.340	1.607
PP04C	49.733	55.136	5.403
PP04D_COD	49.733	49.733	0
P21	0	8.189	8.189
P47T	121	11.579	11.458
REGION	0	0	0
CH03	0	0	0
CODUSU	0	0	0
ANO4	0	0	0
TRIMESTRE	0	0	0
NRO_HOGAR	0	0	0
PONDERA	0	0	0
anio_base	0	0	0

Fuente: elaboración propia en base a INDEC

Tabla 4: Comparación proporción de variables dicotómicas

Variable dicotómica	Proporción en 2024	Proporción en 2025
Mujer	0,51987	0,52564
Jefe del hogar	0,35262	0,35577
Cónyuge o pareja	0,17405	0,17402
Hijo/a del hogar	0,36766	0,36202
Unido/a o casado/a	0,37792	0,37807
Tiene cobertura médica	0,69781	0,68386
Sin cobertura médica	0,30219	0,31614
Secundario completo o más	0,48887	0,49058
Superior universitario completo	0,14426	0,14442
Patrón	0,03452	0,03522
Cuenta propia	0,23569	0,24955
Asalariado	0,72540	0,71064
Trabajador familiar sin remuneración	0,00439	0,00460
Empleo formal	0,56862	0,55577
Empleo informal	0,43138	0,44423
Sector formal	0,69445	0,68319
Sector informal	0,23517	0,24536
Sector hogares	0,07038	0,07146
Establecimiento hasta 5 personas	0,48654	0,50894
Establecimiento de 6 a 40 personas	0,26496	0,25393
Establecimiento de más de 40 personas	0,24850	0,23713
Gran Buenos Aires	0,16232	0,16208
Noroeste	0,21340	0,21589
Noreste	0,10151	0,09487
Cuyo	0,09897	0,09947
Pampeana	0,30025	0,31156
Patagonia	0,12296	0,11611

Fuente: elaboración propia en base a INDEC

Tabla 5: Estadísticas descriptivas de ingreso, laborales y geográficas

Variable	Año	N	Media	Desv. Est.	Min	P25	P50	P75	P99	Max
Ingreso Ocup. Principal (pesos 2025T4)	2024	42.529	352.742	698.449	0	0	0	536.980	2.826.212	21.196.590
	2025	39.724	364.445	727.928	0	0	0	600.000	3.000.000	30.000.000
Ingreso Total Individual (pesos 2025T4)	2024	40.900	528.852	789.448	0	0	0	339.145	3.532.765	23.316.249
	2025	38.084	544.200	843.555	0	0	0	350.000	3.500.000	30.000.000
Patrón	2024	22.076	0,03	0,18	0	0	0	0	1	1
	2025	20.673	0,04	0,18	0	0	0	0	1	1
Cuenta propia	2024	22.076	0,24	0,42	0	0	0	0	1	1
	2025	20.673	0,25	0,43	0	0	0	0	1	1
Asalariado/a	2024	22.076	0,73	0,45	0	0	1	1	1	1
	2025	20.673	0,71	0,45	0	0	1	1	1	1
Trabajador fam. sin rem.	2024	22.076	0,00	0,07	0	0	0	0	0	1
	2025	20.673	0,00	0,07	0	0	0	0	0	1
Empleo formal	2024	21.116	0,57	0,50	0	0	1	1	1	1
	2025	19.688	0,56	0,50	0	0	1	1	1	1
Empleo informal	2024	21.116	0,43	0,50	0	0	0	1	1	1
	2025	19.688	0,44	0,50	0	0	0	1	1	1
Sector formal	2024	20.275	0,69	0,46	0	0	1	1	1	1
	2025	18.948	0,68	0,47	0	0	1	1	1	1
Sector informal	2024	20.275	0,24	0,42	0	0	0	0	1	1
	2025	18.948	0,25	0,43	0	0	0	0	1	1
Sector hogares	2024	20.275	0,07	0,26	0	0	0	0	1	1
	2025	18.948	0,07	0,26	0	0	0	0	1	1
Establ. hasta 5 personas	2024	17.014	0,49	0,50	0	0	0	1	1	1
	2025	15.662	0,51	0,50	0	0	1	1	1	1
Establ. de 6 a 40 personas	2024	17.014	0,26	0,44	0	0	0	1	1	1
	2025	15.662	0,25	0,44	0	0	0	1	1	1
Establ. más de 40 personas	2024	17.014	0,25	0,43	0	0	0	0	1	1
	2025	15.662	0,24	0,43	0	0	0	0	1	1
Gran Buenos Aires	2024	46804	0,16	0,37	0	0	0	0	1	1
	2025	43638	0,16	0,37	0	0	0	0	1	1
Noroeste	2024	46804	0,21	0,41	0	0	0	0	1	1
	2025	43638	0,22	0,41	0	0	0	0	1	1
Noreste	2024	46804	0,10	0,30	0	0	0	0	1	1
	2025	43638	0,09	0,29	0	0	0	0	1	1
Cuyo	2024	46804	0,10	0,30	0	0	0	0	1	1
	2025	43638	0,10	0,30	0	0	0	0	1	1
Pampeana	2024	46804	0,30	0,46	0	0	0	1	1	1
	2025	43638	0,31	0,46	0	0	0	1	1	1
Patagonia	2024	46804	0,12	0,33	0	0	0	0	1	1
	2025	43638	0,12	0,32	0	0	0	0	1	1

Fuente: elaboración propia en base a INDEC

