

Trabajo Práctico Número 2

GitHub: <https://github.com/AguFigueron/Grupo-4---Taller-de-programaci-n/tree/main/TP1>

Parte I: Creación de variables y estadística descriptiva

En la Tabla 1 se presenta la estadística descriptiva de las variables continuas (la matriz completa de 37 variables se adjunta en el Anexo C). La muestra presenta una edad media de 37,4 años (mediana 35) y un promedio de 3,77 miembros por hogar. Los años de educación formal promedian 9,6 años (mediana 11), evidenciando un sesgo hacia niveles de escolarización bajos o incompletos. Las horas semanales trabajadas por el jefe de hogar promedian 39,3 horas, alineadas a una jornada completa. Finalmente, los ingresos (a precios constantes de 2025) exhiben una marcada asimetría a la derecha, con elevadas desviaciones estándar y máximos atípicos.

Tabla 1: Estadísticas descriptivas de variables continuas seleccionadas (EPH 2024T4–2025T4).

Variable	Obs.	Media	Desv. Est.	Mínimo	Mediana (p50)	Máximo
Edad (años)	89.889	37,39	22,13	1	35,0	103
Edad al cuadrado	89.889	1.887,92	1.877,18	1	1.225,0	10.609
Años de educación formal	89.093	9,60	4,92	0	11,0	22
Miembros del hogar	90.442	3,77	1,90	1	4,0	19
Horas semanales trabajadas por el jefe	59.458	39,27	17,30	0	40,0	154
Ingreso ocupación principal (\$ T4-2025)	82.253	\$358.394	\$712.858	\$0	\$0	\$30.000.000
Ingreso total individual (\$ T4-2025)	78.984	\$536.252	\$816.016	\$0	\$339.145	\$30.000.000

Fuente: elaboración propia en base a INDEC

A continuación se presenta la Figura 1 con la matriz de correlaciones para 2025T4 (la de 2024 está disponible en el anexo). Ambas matrices muestran una estructura muy estable. La variable con mayor asociación con la informalidad es la cantidad de años de educación, con una correlación de -0,57 en ambos períodos, indicando que a mayor educación corresponde menor informalidad. El ingreso de la ocupación principal y el tamaño del establecimiento también presentan relaciones negativas con la informalidad, aunque de menor magnitud. Por su parte, el número de miembros del hogar muestra una correlación positiva cercana a \$0,15\$. Finalmente, las correlaciones con la edad, la edad al cuadrado y las horas trabajadas son muy próximas a cero, por lo que no presentan una asociación lineal individual importante. En síntesis, el principal predictor que resulta de este análisis es la educación.

Figura 1: Matriz de correlaciones de Pearson para la muestra de trabajadores independientes (2025T4).




Fuente: elaboración propia en base a INDEC

Parte II: Métodos No Supervisados: PCA

En el plano de los dos primeros componentes se observa una superposición entre trabajadores formales e informales, sin una frontera clara. Los informales se concentran en valores bajos del segundo componente, y los formales en valores positivos. En el Anexo (figura 2) se identifican casos atípicos en valores elevados del segundo componente.

Según los loadings (Figura 2), el primer componente está explicado por la edad y su cuadrado. El segundo componente se relaciona con ingreso, tamaño del establecimiento, educación y horas trabajadas; los miembros del hogar se orientan en sentido contrario. Los formales aparecen con más frecuencia hacia mayores niveles educativos, ingresos y tamaño de establecimiento, representando una diferencia promedio y no una separación completa.


Figura 2: Biplot de PCA: estructura de factores y distribución de la formalidad laboral en independientes.



Fuente: elaboración propia en base a INDEC

La Figura 3 muestra la varianza explicada: los dos primeros componentes concentran el 52,7% de la varianza total, resumiendo más de la mitad de la información. Para superar el 80% de varianza acumulada se requieren cuatro componentes, lo cual es consistente con las correlaciones bajas a moderadas observadas.

Figura 3: Proporción de varianza explicada individual y acumulada por componente principal.



Fuente: elaboración propia en base a INDEC


Parte II: Métodos No Supervisados: *Clúster*

Tabla 2: Matriz de coincidencia: asignación de clústeres por K-Medias (k=2) vs. condición de formalidad real.

Clúster K-Medias (k=2)	Formal	Informal	Total
0	476	2287	2763
1	880	3442	4322
Total	1356	5729	7085

Fuente: Elaboración propia en base a INDEC

Figura 4: Asignación de clústeres por K-Medias (k=2) proyectada sobre el plano de Componentes Principales.




Fuente: elaboración propia en base a INDEC

K-Medias con $k=2$ graficado en la Figura 4 no parece separar correctamente a trabajadores formales e informales. Los informales representan el 82,8% del clúster 0 y el 79,6% del clúster 1, proporciones muy similares a la composición general de la muestra. Por lo tanto, los clústeres reflejan diferencias en las características numéricas de los individuos, pero no reproducen su condición de formalidad. El método del codo (Figura 3 del Anexo) sugiere utilizar $k=3$, ya que a partir de ese valor la reducción de la inercia se vuelve más gradual. Esto indica que la estructura de los datos se representa mejor mediante tres grupos que mediante la división binaria entre formales e informales.

El dendrograma presentado en la Figura 5 muestra cómo las observaciones se agrupan progresivamente según su similitud. Un corte cercano a una distancia de 12 sugiere aproximadamente tres grupos, consistente con el método del codo de K-Medias. Sin embargo, los grupos contienen tanto trabajadores formales como informales, por lo que tampoco se observa una separación clara según la condición laboral. Dado que el dendrograma se construyó sobre una submuestra de 100 observaciones, sus resultados deben interpretarse como ilustrativos.


Figura 5: Dendrograma de clúster jerárquico aglomerativo (Método Ward, submuestra $n=100$).



Fuente: elaboración propia en base a INDEC

En K-Modas con $k=2$, el clúster 0 está compuesto por un 92,4% de trabajadores informales y un 7,6% de formales, mientras que el clúster 1 presenta un 67,4% de informales y un 32,6% de formales. Por lo tanto, el algoritmo identifica dos perfiles con distinta incidencia de formalidad, pero no logra separar completamente ambas condiciones, ya que los trabajadores informales continúan siendo mayoría en los dos grupos. El método del codo aplicado a K-Modas (Figura 6) sugiere una solución de $k=5$. A partir de ese valor, la reducción general del costo de disimilitud se vuelve menor, aunque el quiebre es menos marcado que en K-Medias. La diferencia entre los resultados se puede explicar porque ambos métodos utilizan variables y criterios de agrupamiento distintos. Mientras que K-Medias trabaja con las siete variables numéricas estandarizadas, K-Modas utiliza las variables binarias del TP1 y las nuevas variables del TP2 previamente categorizadas.

Figura 6: Método del Codo para K-Modas: costo de disimilitud sobre variables categóricas sociodemográficas.



Fuente: elaboración propia

En conjunto, los resultados muestran que la informalidad de los trabajadores independientes se relaciona principalmente con la educación, el ingreso y el tamaño del establecimiento, aunque las asociaciones se mantienen estables entre 2024 y 2025. El PCA resume el 52,7% de la variabilidad en sus dos primeros componentes, pero presenta una amplia superposición entre trabajadores formales e informales. De manera consistente, K-Medias con $k=2$ no reproduce la división entre ambas condiciones laborales, mientras que K-Modas identifica perfiles con distinta incidencia de informalidad, aunque sin lograr una separación completa. Los métodos del codo sugieren tres grupos para las variables numéricas y cinco para las categóricas. La estructura de los datos refleja múltiples perfiles socioeconómicos y no una división natural exclusivamente binaria entre formalidad e informalidad. Los métodos no supervisados resultan útiles para explorar esta heterogeneidad, pero no deben interpretarse como métodos de clasificación de la condición laboral.

Parte III Uso de Herramientas de IA y Reflexión Final

Las herramientas de inteligencia artificial se utilizaron para organizar el código, detectar errores, mejorar las visualizaciones y orientar la interpretación de los resultados. Su aporte fue especialmente útil en la implementación del PCA y de los métodos de *clustering*, así como en la revisión de la coherencia entre tablas, gráficos y conclusiones. En consecuencia, la IA funcionó como una herramienta de asistencia, y sus sugerencias fueron verificadas y adaptadas críticamente antes de incorporarse al trabajo.

Tiempo total aproximado dedicado al trabajo: 16 horas.

Ápndice: uso de herramientas de IA

LLM: Gemini

“nuestra profesora de programacion hizo mucho hincapie en la importancia de los graficos con buena visualizacion, con tres principios: menos es mas, los ojos leen de arriba a abajo y de izquierda a derecha, y cuidar la jerarquia visual. te paso nuestro notebook, con lo que hicimos hasta ahora, para que me ayudes armando graficos que cumplan esos tres principios”
.py adjunto

“me ayudas emprolijando estos otros graficos bajo el mismo criterio?” *.py adjunto*

“está demasiado claro el naranja en el grafico de outliers y el biplot, se pierden” *imagen adjunta*

“las etiquetas se tapan entre sí, no habria que achicar el font y/o sacarle la negrita?” *imagen adjunta*

“la profesora remarcó bastante graficos con etiquetas de ejes verticales y el dendrograma las tiene verticales. se podrá hacer una version que acople las que estan repetidas? ves que dice formal 5 veces, despues informal 14, y asi.” *imagen adjunta*

LLM: ChatGPT

“pase parte del TP 1 al inicio del TP 2, revisa que ya está pronto para que avance con los puntos del del TP2 o si me falto pasar algo” *ipynb adjunto*

“Ayudame a generar la variable educ en base a CH12, CH13 y CH14. Por ejemplo, si dice que el nivel más alto de educación es “Secundario” (CH12), “Sí” finalizó este nivel (CH13) y el último año que aprobó (CH14) fue “sexto”, entonces puede asumir que tiene educ=12, ósea 12 años de educación formal. Para los casos en que no completo el ultimo estudio, imputar el ultimo año completo. Genera tambien una tabla para revisar los resultados”

“Ayudame a revisar si quedo bien este notebook” *ipynb adjunto*

“intente ejecutar todo y me dio este error” *error pegado*

“ayudame a generar tablas de control para revisar que las variables horastrab y nhogar estén bien”

“Generame un código base para aplicar PCA las variables: edad, edad2, educ, horastrabj, nhogar, P21, y PP04C de la base de ocupados, quiero tambien generar un gráfico de dispersión con los índices (scores) calculados del primer y segundo componente de PCA”

“te paso la notebook con lo que armé en base a tu recomendación, dime si se ven errores en lo que corrí hasta ahora y que está pasando que no corre la parte del gráfico” *ipynb adjunto*

“te parece que este código está completo? Que no me esté faltando nada de lo pedido en la consigna?”

“Ayudame a re-hacer el código del punto 6.b teniendo pero agregando variables_tp2_categorizadas, paso la notebook actual. revisa que no queden gráficos redundantes” *ipynb adjunto*


Anexo

Tabla 1: Estadísticas descriptivas completas

Categoría	Variable	Obs.	Media / Prop.	Desv. Est.	Mediana (p50)
Sociodemográfica	Edad (años)	89.889	37,39	22,13	35,0
	Miembros por hogar	90.442	3,77	1,90	4,0
	Mujer (%)	90.442	52,3%	—	—
	Cobertura médica (%)	90.297	69,1%	—	—
Educación	Años de educación (educ)	89.093	9,60	4,92	11,0
	Secundario completo o más (%)	90.442	49,0%	—	—
	Superior universitario completo (%)	90.442	14,4%	—	—
Laboral	Población Ocupada (%)	90.442	45,1%	—	—
	Horas trabajadas jefe de hogar	59.458	39,27	17,30	40,0
Categoría Ocup. (s/Ocupados)	Patrón (%)	42.749	3,5%	—	—
	Cuenta Propia (%)	42.749	24,2%	—	—
	Asalariado (%)	42.749	71,8%	—	—
Ingresos (\$ T4-2025)	Ingreso Ocupación Principal	82.253	\$358.394	\$712.858	\$0
	Ingreso Total Individual	78.984	\$536.252	\$816.016	\$339.145


Fuente: elaboración propia en base a INDEC

Figura 1: Matriz de correlaciones de Pearson para la muestra de trabajadores independientes (2024T4).




Fuente: elaboración propia en base a INDEC

Figura 2: Distribución de scores en los Componentes Principales 1 y 2 con detección de observaciones atípicas



Fuente: elaboración propia en base a INDEC

Figura 3: Método del Codo (Elbow plot) para la determinación de k óptimo en K-Medias ($k = 1$ a 40)



Fuente elaboración propia en base a INDEC