

Trabajo Práctico Número 3

GitHub: <https://github.com/AguFigueron/Grupo-4---Taller-de-programaci-n/tree/main>

A. Enfoque de validación: 2024 como entrenamiento, 2025 como testeo

Para evaluar la capacidad predictiva del modelo en datos nuevos, se utilizó la técnica de validación cruzada. Como en este trabajo la muestra se dividió por año para la predicción (2024 para entrenamiento y 2025 para testeo), la exogeneidad de las particiones se puede perder. Por este motivo, en la Tabla 1 se analiza la diferencia de medias entre ambos períodos.

Los resultados muestran que seis de las variables analizadas presentan diferencias estadísticamente significativas. La diferencia estandarizada más marcada corresponde al ingreso, seguida por la proporción de la Región Pampeana y las horas trabajadas. El sector informal y la educación muestran diferencias al 5%, y la edad al 10%. Esto indica que las muestras de 2024 y 2025 no son estadísticamente equivalentes: existen diferencias sistemáticas que van más allá de la variación aleatoria. Lo cual, puede llegar a sesgar la evaluación del modelo.

Tabla 1: Diferencia de medias (Variables con significancia estadística)

Variable	Media 2024	Media 2025	Dif. Estandarizada	p-valor
Sector: informal	0.602	0.624	0.045**	0.0171
Región: Pampeana	0.314	0.342	0.061***	0.0010
Edad	44.760	45.251	0.035*	0.0632
Ingreso	747.329.7	849672.7	0.092***	0.0000
Educación	11.563	11.380	-0.048**	0.0113
Horas trabajadas	38.544	39.702	0.061***	0.0028

Fuente: elaboración propia en base a INDEC
(Nota: La tabla completa se encuentra en el Anexo).
*** $p < 0.01$ | ** $p < 0.05$ | * $p < 0.10$.

B. Modelo de Regresión Logística: Extensión el trabajo de Maurizio & Monsalvo (2021)

Para predecir la probabilidad de pertenecer al sector informal, se estimaron dos modelos de regresión logística (Tabla 2): un modelo base y otro basado en la metodología de Maurizio & Monsalvo (2021), en adelante Modelo MM. Dado que el algoritmo requiere bases sin nulos, los datos faltantes se imputaron previamente mediante K-vecinos cercanos, redondeando los resultados para mantener el formato binario de las variables categóricas.

Los resultados muestran que los años de educación y el tamaño del establecimiento se asocian negativamente con la probabilidad de ser informal, mientras que la categoría de patrón la incrementa drásticamente. Al incluir el estatus de informalidad previo (Modelo

MM), se observa que el pasado laboral tiene mucho peso (con un *odds ratio* de 16.7), lo cual, demuestra una alta persistencia de la informalidad en el mercado laboral. Al sumar esta variable, se modifica levemente la magnitud del resto de los factores, pero su rumbo se mantiene igual.

Sin embargo, es fundamental advertir un problema técnico en el Modelo MM respecto a la variable de establecimientos de más de 40 personas. En la submuestra evaluada, esta categoría presenta solo seis observaciones y todas corresponden a trabajadores formales, lo cual, genera la separación perfecta, impidiendo que el algoritmo converja y causa que el error estándar del coeficiente explote. Por este motivo, el coeficiente estimado para esta variable no debe interpretarse analíticamente y los resultados de esta especificación deben analizarse con cuidado.

Tabla 2: Resultados de la Regresión Logística (Selección de variables principales)


Variable	Coef 2024	Odds Ratio 2024	Coef 2025 MM	Odds Ratio 2025 MM
Constante	21.883	3.18×10^9	23.647	1.86×10^{10}
Educación	-1.226	0.294	-1.512	0.220
Patrón	4.683	108.06	8.992	8040.37
Establecimiento de 6 a 40 personas	-10.436	0.000	-18.536	0.000
Establecimiento de más de 40 personas	-13.947	0.000	-36.278	0.000
Informal (2024)	-	-	2.816	

Fuente: elaboración propia en base a INDEC
(Nota: La tabla completa se detalla en el Anexo).

En el Gráfico 1 se observa probabilidad predicha de informalidad según los años de educación: la acumulación de capital humano reduce la propensión a la informalidad, aunque el efecto es marcadamente no lineal.

Para los trabajadores con 10 años o menos de escolaridad, la probabilidad predicha de informalidad se mantiene cercana al 100%. El punto de inflexión del modelo está en el umbral de 0.5: clasifica como informales a quienes tienen 15 años de educación o menos. Recién a partir de los 16 años (nivel superior o universitario), la probabilidad cae por debajo del umbral y predice la inserción formal. En resumen, el modelo muestra que el salto de capital humano necesario para salir de la informalidad se concreta recién al alcanzar los niveles educativos más altos.

Gráfico 1: Probabilidad predicha de informalidad según años de educación (Modelo 2024 aplicado a datos 2025).



Fuente: elaboración propia en base a INDEC

C. Desempeño del modelo y predicción afuera de la muestra

Para evaluar si las estimaciones logran generalizar, se analizó el desempeño de ambos clasificadores en la muestra de testeo de 2025. Como muestran la Tabla 3 y las matrices de confusión (Tablas 4 y 5), incorporar el estatus de informalidad previo (Modelo MM) mejora el poder predictivo en todas las métricas.

Tabla 3: Métricas de Desempeño en muestra de testeo (2025)

Métrica	Modelo 2024	Modelo MM
Sensibilidad (TPR)	0.967	0.980
Tasa Falso Positivo (FPR)	0.195	0.092
Accuracy	0.932	0.965
AUC	0.983	0.991

Fuente: elaboración propia en base a INDEC

El Modelo MM incrementa la *accuracy* general (de 0.932 a 0.965) y clasifica sustancialmente mejor ambas categorías. Por un lado, aumenta la sensibilidad (TPR) de 0.967 a 0.980, detectando correctamente a una mayor proporción de trabajadores informales (1202 frente a los 1186 del modelo base). Por otro lado, reduce a menos de la mitad la tasa de falsos positivos (FPR cae de 0.195 a 0.092), lo que implica que se equivoca mucho menos al clasificar como informales a individuos que en realidad son formales.

Tabla 4: Matriz de Confusión - Modelo 2024

	Predicho: Formal	Predicho: Informal
Real: Formal	307	31
Real: Informal	24	1202

Fuente: elaboración propia en base a INDEC


Tabla 5: Matriz de Confusión - Modelo MM

	Predicho: Formal	Predicho: Informal
Real: Formal	307	31
Real: Informal	24	1202

Fuente: elaboración propia en base a INDEC

Esta superioridad se visualiza claramente en el Gráfico 2. La curva ROC del Modelo MM se acerca de manera más pronunciada al vértice superior izquierdo, alcanzando un Área bajo la curva de 0.991 frente al 0.983 del modelo base. Esto confirma que el Modelo MM posee un poder de discriminación sobresaliente para distinguir entre trabajadores formales e informales.

Gráfico 2: Curva ROC - Comparación de capacidad predictiva entre el Modelo 2024 y el Modelo MM.



Fuente: elaboración propia en base a INDEC

En el contexto de la política pública para la Secretaría de Trabajo, el objetivo es identificar trabajadores precarizados para asignar recursos escasos de un programa de formalización. Esto plantea el clásico *trade-off* entre el Error de Tipo I y el Error de Tipo II. Cometer un Error de Tipo I implica clasificar como informal a un trabajador formal, desperdiciando recursos estatales en alguien que no los necesita. Por el contrario, un Error de Tipo II supone no detectar a un trabajador verdaderamente precarizado, excluyéndolo injustamente del programa.

Como la premisa establece que los recursos son estrictamente "escasos", la prioridad debería ser la eficiencia presupuestaria: minimizar los falsos positivos (Error de Tipo I) para evitar filtraciones hacia sectores no vulnerables. Bajo este criterio, el Modelo MM resulta indiscutiblemente superior. No solo mejora la focalización y evita excluir a los más vulnerables (dada su mayor sensibilidad), sino que su drástica reducción en la tasa de falsos positivos garantiza una asignación de fondos mucho más certera y eficiente que la del Modelo 2024.

Conclusión

En conclusión, el análisis demuestra que la informalidad laboral es un problema que se arrastra de un año a otro. Incluir el estatus previo de informalidad (Modelo MM) mejora drásticamente la predicción frente al modelo transversal (Modelo 2024): incrementa la sensibilidad y reduce los falsos positivos a menos de la mitad. Además, se comprobó que el capital humano (educación) y el mayor tamaño del establecimiento actúan como factores protectores contra la precarización. Sin embargo, las diferencias sistemáticas halladas entre 2024 y 2025 advierten sobre los límites de la validación cruzada temporal. Al dividir los datos por año, la exogeneidad de la muestra puede verse afectada por dinámicas estructurales del mercado laboral.

Reflexión final: IA

El uso de Inteligencia Artificial resultó muy útil para agilizar la programación en Python y resolver dudas técnicas puntuales sobre formato, como la estructura para guardar y levantar bases en Colab o el orden de los elementos en las notas al pie de las tablas. Además, sirvió para el armado de tablas y gráficos que cumplieran con los estándares de visualización necesarios. Por último, sirvió como un apoyo a la redacción del informe, tanto en estilo, como para entender la estructura que suele tener un ensayo académico.

Apéndice: Uso de herramientas de IA

LLM: ChatGPT

“Ayúdame a generar el código para guardar y luego levantar las mismas bases en colab”

“ayúdame a evaluar como queda este código, dime si cumple con la pauta y si se entiende ”

“te paso el avance que hay hasta ahora, revisa la coherencia de los resultados” * .py adjunto *

“dime en que parte tendría que agregar la corrección de las dummies”

“en base a este ejemplo, ayudame con el código para generar la matriz de confusión y la curva ROC”

“ayúdame a revisar el código adjunto, revisa que esté todo lo que pide la pauta * .py adjunto *

LLM: Gemini

“en base a estos principios de visualización: menos es más, contraste y legibilidad, jerarquía visual; ayudame emprolijando estos dos gráficos. te adjunto el notebook” * .py adjunto *

“revisas la redacción de estos párrafos? sin cambiar mucho el texto, ni su extensión, simplemente que tengan sentido” *texto pegado*

“perdi la celda con el código para este gráfico, y no tiene mas los títulos en bold y eso. me lo corregis para cumplir los criterios de visualización? (deja la etiqueta del umbral a la derecha porque el gráfico arranca a la izquierda y queda feo sino)” *código pegado*

“en papers académicos, en tablas con significancia, qué va primero, la fuente o el ***?”

Anexo

Tabla 1: Diferencia de medias y balance poblacional (Versión extendida).

Variable	Media 2024	Media 2025	Diferencia	Dif. estandarizada	p-value
mujer	0.395	0.410	0.015	0.031	0.1024
jefe_hogar	0.532	0.527	-0.004	-0.009	0.6379
conyuge_pareja	0.238	0.242	0.004	0.010	0.5773
hijo_hogar	0.178	0.180	0.001	0.003	0.8547
con_pareja	0.589	0.590	0.001	0.002	0.8973
tiene_cobertura_medica	0.549	0.535	-0.013	-0.027	0.1513
patron	0.132	0.127	-0.004	-0.013	0.4770
sector_informal	0.602	0.624	0.022**	0.045	0.0171
sector_hogares	0.000	0.000	0.000	NaN	NaN
establecimiento_6_a_40_personas	0.030	0.029	-0.001	-0.005	0.7849
establecimiento_mas_40_personas	0.004	0.004	-0.000	-0.002	0.9184
region_noroeste	0.212	0.216	0.003	0.008	0.6756
region_noreste	0.102	0.097	-0.005	-0.016	0.3811
region_cuyo	0.108	0.106	-0.002	-0.007	0.7077
region_pampeana	0.314	0.342	0.029***	0.061	0.0010
region_patagonia	0.087	0.085	-0.001	-0.005	0.7884
CH06	44.760	45.251	0.490*	0.035	0.0632
P21_2025T4	747329.728	849672.753	102343.025***	0.092	0.0000
edad2	2201.995	2246.314	44.319*	0.034	0.0736
educ	11.563	11.380	-0.184**	-0.048	0.0113
horastrabj	38.544	39.702	***	0.061	0.0028
nhogar	3.436	3.464	0.028	0.016	0.3897

Fuente: elaboración propia en base a INDEC

*** p < 0.01 | ** p < 0.05 | * p < 0.10

Tabla 2: Tabla de contingencia: Establecimientos de 6 a 40 personas vs. Estatus de informalidad.

informal			
establecimiento_6_a_40_personas	0	1	All
0	295	1224	1519
1	43	2	45
All	338	1226	1564

Fuente: elaboración propia en base a INDEC

Tabla 3: Tabla de contingencia: Establecimientos de más de 40 personas vs. Estatus de informalidad.

informal			
establecimiento_mas_40_personas	0	1	All
0	332	1226	1558
1	6	0	6
All	338	1226	1564

Fuente: elaboración propia en base a INDEC

Tabla 3: Tabla de contingencia: Categoría ocupacional (Patrón) vs. Estatus de informalidad.

informal			
patron	0	1	All
0	293	1063	1356
1	45	163	208
All	338	1226	1564

Fuente: elaboración propia en base a INDEC