

Trabajo Práctico Número 4: Métodos de regularización y CART

GitHub: <https://github.com/AguFigueron/Grupo-4---Taller-de-programaci-n/tree/main>


A. Modelo de Regresión Logística con Regularización: Ridge y LASSO

Para esta etapa se utilizó la matriz ocupados_X_2025_MM incorporando el rezago del estado de informalidad de 2024. Atendiendo a las correcciones metodológicas del trabajo previo, se excluyeron los predictores endógenos utilizados para construir la variable objetivo (categoría de patrón y tamaño del establecimiento), así como resultados directos del mercado laboral (ingreso y horas trabajadas). De esta forma, las estimaciones se basan en 17 variables exógenas, eliminando el sesgo por fuga de información.

La Figura 1 muestra la evolución de los coeficientes estimados de la regresión logística a medida que aumenta la penalización (en escala logarítmica), comparando los esquemas de regularización LASSO (Panel A) y Ridge (Panel B). La línea roja punteada indica el λ óptimo seleccionado por validación cruzada (5 folds) según el criterio de accuracy.

En ambos paneles se observa que las variables Años de educación e Informal en 2024 son las de mayor magnitud absoluta y, en consecuencia, las últimas en verse afectadas por la penalización, lo que sugiere que son los predictores con mayor poder explicativo sobre la condición de informalidad laboral. Le siguen en importancia Con Pareja, Sector Informal, Cónyuge/Pareja y Jefe/a de Hogar, mientras que las dummies regionales y Edad muestran coeficientes cercanos a cero, indicando un aporte marginal más limitado en este modelo.


Figura 1: Gráficos de trayectoria de los coeficientes según la intensidad de penalización



Fuente: Elaboración propia

Con el fin de evaluar la sensibilidad del error de clasificación a la intensidad de la penalización y de justificar la elección de λ mediante validación cruzada, se presenta a continuación (en la Figura 2) la distribución del error de predicción en los 5 folds para cada valor de λ evaluado, tanto para el modelo LASSO como para Ridge.

Figura 2: Gráficos de validación según la intensidad de penalización (5-Folds)



Fuente: Elaboración propia

En el Panel A (LASSO), se observa una meseta de bajo error ($\sim 7.5\%$) para penalizaciones débiles, con un mínimo claro en $\lambda = 1$ (7.48%, resaltado en azul), que además presenta la menor dispersión entre folds de todo el panel; a partir de ese punto el error crece de forma marcada, hasta colapsar a $\sim 78\%$ para $\lambda = 10^3$, donde el modelo anula prácticamente todos los coeficientes y pierde capacidad predictiva. En el Panel B (Ridge), en cambio, el error se mantiene estable y bajo (entre 7.6% y 7.7%) a lo largo de todo el extremo inferior de la grilla, sin exhibir un mínimo interior definido, y solo comienza a deteriorarse hacia penalizaciones altas ($\lambda \geq 10^2$); el cv seleccionado (10^{-5}) se ubica en el extremo menos penalizado evaluado, consistente con el límite inferior de la grilla de hiperparámetros identificado previamente. Cabe destacar que ambos paneles utilizan escalas verticales distintas (0-80% en LASSO vs. 6-22% en Ridge), por lo que la comparación directa de las alturas de las cajas puede inducir a error: en términos absolutos, el error mínimo de ambos modelos es prácticamente equivalente (7.48% en LASSO vs. 7.61% en Ridge).


Un resultado a destacar es que el λ óptimo difiere entre modelos: LASSO selecciona un valor intermedio ($\lambda = 1$), mientras que Ridge converge a una solución de esquina en el extremo inferior de la grilla ($\lambda \approx 10^{-5}$, $C \approx 100.000$). Esto indica que, dentro del rango probado, la CV no encuentra evidencia de que restringir los coeficientes vía L2 mejore el accuracy de validación. El modelo simplemente no está sobreajustando lo suficiente como para que el accuracy de validación empeore — es decir, el "codo" donde la varianza empieza a dominar al sesgo puede estar fuera del rango que probamos.

A continuación se presenta la comparación de los coeficientes estimados por el modelo Logit sin penalizar frente a sus versiones regularizadas con LASSO y Ridge, con los λ óptimos calculados por el método de validación cruzada.

B. Árboles

El costo de complejidad óptimo seleccionado mediante 5-fold cross-validation fue de 0.003543. Para valores muy bajos de α el árbol conserva mayor complejidad, mientras que una poda moderada permite reducir la varianza del modelo sin deteriorar su capacidad de clasificación. A partir de niveles mayores de penalización el error vuelve a aumentar, reflejando el mayor sesgo asociado a árboles excesivamente simples. De esta manera se selecciona el valor que minimiza el error promedio de validación.

Figura 3: Error de clasificación en función de la penalidad por poda (CART)



Fuente: Elaboración propia

No hay una relación directa o recíproca entre los coeficientes anulados por la penalización L1 de LASSO y las métricas de importancia de variables en CART. Mientras que LASSO opera sobre una estructura logística lineal seleccionando predictores al forzar sus parámetros a cero, CART evalúa la capacidad de las variables para disminuir la impureza mediante particiones recursivas, pudiendo descartar un predictor si su información explicativa ya resulta redundante tras un corte previo. En consecuencia, que una variable presente importancia nula en CART no implica que reciba un coeficiente de cero en el modelo LASSO.

El árbol (figura A.1) podado presenta una estructura parsimoniosa, la clasificación se realiza prácticamente a partir de dos predictores, Años de educación e Informal en 2024. La educación constituye el primer criterio de partición y concentra la mayor parte de la reducción de impureza. Para los individuos ubicados por debajo del primer umbral educativo, el árbol predice mayoritariamente informalidad. Entre quienes superan dicho umbral, el estado laboral de 2024 constituye el siguiente criterio de separación, confirmando la fuerte persistencia temporal de la informalidad.

C. Comparación entre métodos

En el Anexo se detallan las matrices de confusión completas para las cuatro especificaciones.. En la siguiente tabla se presenta información resumida de las principales métricas de desempeño de los modelos.


Tabla 2: Desempeño de los modelos (5-fold CV, umbral $p = 0.5$)

Modelo	Accuracy	1–Accuracy	Sensibilidad	Especificidad	FP	FN
Logit	0.9246	0.0754	0.9625	0.7870	72	46
LASSO	0.9252	0.0748	0.9625	0.7899	71	46
Ridge	0.9239	0.0761	0.9617	0.7870	72	47
CART	0.9316	0.0684	0.9600	0.8284	58	49

Fuente: Elaboración propia

Al umbral de clasificación $p=0.5$ CART presenta el menor error de clasificación (6,84%), frente a valores cercanos a 7,5% en las regresiones logísticas. La mejora predictiva del método no lineal existe, aunque es moderada. Su principal ventaja en esta aplicación proviene de una mayor especificidad y una reducción de falsos positivos. Por otro lado, LASSO y Logit alcanzan una sensibilidad ligeramente superior. Logit mantiene la interpretación paramétrica más tradicional, LASSO añade selección de variables y CART ofrece reglas de clasificación intuitivas mediante el árbol podado.

Figura 4: Curvas ROC - Comparación de Modelos



Fuente: Elaboración propia

¿Cambió su respuesta con respecto a cuál es el “mejor” modelo para asignar recursos escasos a los más necesitados?

Ante un presupuesto estrictamente limitado, el costo de cometer un Error de Tipo I (falso positivo) es sumamente elevado, ya que implica desviar recursos estatales hacia trabajadores formales. Bajo este criterio de eficiencia, el modelo CART resulta el más adecuado, dado que presenta la mayor especificidad (0.8284) y minimiza drásticamente las filtraciones del programa. No obstante, si el objetivo de política pública priorizara minimizar la exclusión de trabajadores verdaderamente vulnerables (Error de Tipo II), las especificaciones logísticas ofrecerían una sensibilidad ligeramente superior

D. Herramientas de IA y reflexión final

Durante la realización del trabajo utilizamos diversas herramientas de IA como apoyo para la programación y revisión de resultados. Su utilidad fue menor en decisiones metodológicas específicas de nuestra base, ya que las mismas están en base a la consigna, recomendaciones de la docente, particularmente para la construcción de las variables y definición de los modelos. La IA funcionó principalmente como apoyo para programar, revisar y discutir resultados, mientras que la selección final de procedimientos y su interpretación quedaron a cargo del grupo. Para la realización completa de este trabajo práctico, el grupo dedicó un tiempo total estimado de 21 horas.

Apéndice: Uso de herramientas de IA

LLM: ChatGPT

“estoy queriendo volver a correr el TP3 para guardar las bases pero da error, dime si corrió lo suficiente como para poder guardar las bases o es un error que tenga que solucionar ahora”

“te paso la primer parte de controles y estandarización, dime que tal se adapta a lo solicitado por la letra del tp”

“te paso como queda el script con hasta el punto a.1, ayudame a corregirlo”

“ayudame a modificar el codigo de los boxplots para que queden mejor en base a estos principios de visualizacion: menos es más, contraste y legibilidad, jerarquia visual”

“me da el siguiente error, puedes pasarme el codigo para solucionarlo?”

“ayudame a revisar que aspectos faltan completar”

LLM: Gemini

“estoy haciendo la siguiente consigna del tp4, me ayudas revisando el codigo?” *consigna y codigo pegado*

“creo que estos graficos no cumplen con los principios de visualizacion que te mencione, me ayudas a emprolijarlos?” *graficos trayectoria coeficientes* y *grafico de error de clasificacion*

“ayudame revisando la redaccion en estas secciones” *parrafos del informe*

“veo muy saturados los colores de la matriz de confusion, me ayudas cambiandolos?” *codigo pegado*

“si estoy sacando los titulos de los graficos para ponerlos en el informe directamente, tengo que sacar los que estan para cada panel tambien?” *graficos de trayectorias*

Anexo


Tabla A.1: Tabla de coeficientes de los modelos

Variable	Logit sin penalidad	EE Logit	LASSO	Ridge
mujer	-0.2238	0.2252	-0.197	-0.2213
jefe_hogar	-0.7436	0.6876	0	-0.7488
conyuge_pareja	-1.0966	0.7372	-0.2638	-1.1039
hijo_hogar	-0.5724	0.6916	0	-0.5704
con_pareja	0.7517	0.3109	0.576	0.758
tiene_cobertura_medica	0.0295	0.2905	0	0.0289
sector_informal	0.4207	0.2714	0.3737	0.4182
region_noroeste	0.2389	0.3771	0.3356	0.2487
region_noreste	-0.3138	0.4374	-0.0358	-0.309
region_cuyo	-0.2363	0.4148	0	-0.2321
region_pampeana	-0.1941	0.3308	-0.0275	-0.191
region_patagonia	0.3257	0.4932	0.3148	0.3359
CH06	-0.0554	0.7339	-0.1592	-0.0111
edad2	-0.1967	0.7125	-0.0829	-0.2403
educ	-2.6997	0.2255	-2.5916	-2.7002
nhogar	-0.1793	0.1423	-0.1148	-0.1801
informal_2024	2.2656	0.221	2.2881	2.2649


Fuente: Elaboración propia

Figura A.1: Árbol de decisión podado e importancia de los predictores

Panel A. Árbol de decisión podado




Panel B. Importancia de los predictores



Fuente: Elaboración propia

Figura A.2: Matrices de confusión



Fuente: Elaboración propia